

QUESTION ANSWERING SOBRE O EUROVISION SONG CONTEST

SPLN



OBJETIVO


Desenvolver um sistema de Question Answering (QA) capaz de responder automaticamente a perguntas sobre o Eurovision Song Contest, utilizando técnicas modernas de Retrieval-Augmented Generation (RAG).

- Construir e processar um corpus textual
- Implementar retrieval lexical (TF-IDF) e semântico (S-BERT)
- Desenvolver sistemas QA extrativo e abstrativo
- Comparar diferentes abordagens de retrieval e QA

EURO  **vision**
SONG CONTEST

Pergunta → Retrieval → Contexto → Resposta

ARQUITETURA



CONSTRUÇÃO DO CORPUS

```
00_extrai.py

regex_esc = re.compile(
    r'href="/wiki/Eurovision_Song_Contest_(195[6-9]|19[6-9]\d|20[0-1]\d|202[0-6])"'
)
```

- Scraping automático da Wikipédia
- Eurovision + Junior Eurovision
- Regex para links dinâmicos
- Limpeza de HTML
- Remoção de ruído

```
A processar: Junior Eurovision Song Contest 2024...
-> Sucesso: Junior_Eurovision_Song_Contest_2024.txt
A processar: Junior Eurovision Song Contest 2025...
-> Sucesso: Junior_Eurovision_Song_Contest_2025.txt
A processar: Junior Eurovision Song Contest 2026...
-> Sucesso: Junior_Eurovision_Song_Contest_2026.txt

--- INICIANDO FESTIVAIS ESPECIAIS E SPIN-OFFS ---
A processar: Eurovision Dance Contest - General Page...
-> Sucesso: Eurovision_Dance_Contest_General.txt
A processar: Eurovision Dance Contest 2007...
-> Sucesso: Eurovision_Dance_Contest_2007.txt
A processar: Eurovision Dance Contest 2008...
-> Sucesso: Eurovision_Dance_Contest_2008.txt
A processar: American Song Contest...
-> Sucesso: American_Song_Contest.txt
A processar: Eurovision Song Contest Asia...
-> Sucesso: Eurovision_Song_Contest_Asia.txt

[Dataset Concluído] Todos os ficheiros foram gerados na pasta 'fontes'!
```

PROCESSAMENTO DO CORPUS

- limpeza textual
- chunking
- sliding window
- overlap

```
corpus_processado.json

{
  "doc_id": 44,
  "fonte": "Eurovision_Song_Contest_1996.txt",
  "texto": "Eurovision Song Contest 1996 Location
The 1996 contest took place in Oslo, Norway, following
the country's victory at the 1995 contest with..."
},
```

```
chunks.json

{
  "chunk_id": 1528,
  "doc_id": 74,
  "fonte": "Eurovision_Song_Contest_2026.txt",
  "texto": "Semi-final allocation draw The draw to
determine the participating countries' semi-finals took
place on 12 January 2026 at 19:00 CET, at the Vienna City
Hall..."
},
```


RETRIEVAL TF-IDF

O primeiro módulo de retrieval desenvolvido foi baseado em TF-IDF, utilizando uma abordagem lexical clássica para pesquisa de informação no corpus. Cada chunk textual é convertido num vetor numérico TF-IDF e a relevância entre a pergunta e os documentos é calculada através de cosine similarity. Além disso, foi aplicado um sistema de bonus lexical, reforçando chunks com palavras importantes.

```
Inserir uma pergunta (ou 'sair'): who win 2017 eurovision?
```

```
===== RESULTADOS =====
```

```
Resultado #1
```

```
Score: 1.0854
```

```
Fonte: Eurovision_Song_Contest_2017.txt
```

```
Texto:
```

```
questioned by the police at the venue police office." Other awards In addition to the main winner's trophy, the Marcel Bezençon Awards and the Barbara Dex Award were contested during the 2017 Eurovision Song Contest. The OGAE, "General Organisation of Eurovision Fans" voting poll also took place before the contest. Marcel Bezençon Awards The Marcel Bezençon Awards, organised since 2002 by Sweden's then-Head of Delegation and 1992 representative Christer Björkman, and 1984 winner Richard Herrey, honours songs in the contest's final. The awards are divided into three categories: Artistic Award, Composers Award, and Press Award. The winners were revealed shortly before the final on 13 May. OGAE
```

```
=====
```

```
Resultado #2
```

```
Score: 1.0110
```

```
Fonte: Eurovision_Song_Contest_2017.txt
```

```
Texto:
```

```
after 1956. Miroshnychenko has previously co-hosted the Junior Eurovision Song Contest in 2009 and 2013. Promotional emojis It was announced on 30 April that the creative teams from both the Eurovision network and Twitter had worked together to create three emoji that would accompany specific promotional hashtags for the duration of the contest. The heart emoji would appear alongside #ESC2017 and #Eurovision, while the winners' trophy emoji would be used for #12Points and #douzepoints. The final emoji is the logo for the contest, which would appear alongside #CelebrateDiversity, the slogan of the contest. Opening and interval acts The EBU released details regarding the opening and interval a
```


RETRIEVAL SEMÂNTICO (S-BERT)

Foi desenvolvido um retriever semântico baseado em Sentence-BERT (S-BERT). Ao contrário do TF-IDF, o S-BERT transforma cada chunk textual em um embedding vetorial denso, capaz de representar o significado semântico do texto. A pergunta do utilizador também é convertida num embedding e a relevância entre query e chunks é calculada através de cosine similarity.

Foi ainda aplicado um re-ranking híbrido, combinando:

- similaridade semântica;
- bonus lexical para palavras-chave importantes.

```
Pergunta (ou 'sair'): who win 2017 eurovision?

===== RESULTADOS S-BERT =====

Resultado #1
Score: 1.5281
Fonte: Eurovision_Song_Contest_2017.txt

Texto:
questioned by the police at the venue police office." Other awards In addition to the main winner's trophy, the Marcel Bezençon Awards and t
he Barbara Dex Award were contested during the 2017 Eurovision Song Contest. The OGAE, "General Organisation of Eurovision Fans" voting poll
also took place before the contest. Marcel Bezençon Awards The Marcel Bezençon Awards, organised since 2002 by Sweden's then-Head of Delega
tion and 1992 representative Christer Björkman, and 1984 winner Richard Herrey, honours songs in the contest's final. The awards are divided
into three categories: Artistic Award, Composers Award, and Press Award. The winners were revealed shortly before the final on 13 May. OGAE

-----

Resultado #2
Score: 1.4737
Fonte: Eurovision_Song_Contest_2017.txt

Texto:
after 1956. Miroshnychenko has previously co-hosted the Junior Eurovision Song Contest in 2009 and 2013. Promotional emojis It was announced
on 30 April that the creative teams from both the Eurovision network and Twitter had worked together to create three emoji that would accom
pany specific promotional hashtags for the duration of the contest. The heart emoji would appear alongside #ESC2017 and #Eurovision, while t
he winners' trophy emoji would be used for #12Points and #douzepoints. The final emoji is the logo for the contest, which would appear along
side #CelebrateDiversity, the slogan of the contest. Opening and interval acts The EBU released details regarding the opening and interval a
```

QA EXTRATIVO

Foi desenvolvido um módulo de Question Answering extrativo, responsável por localizar diretamente a resposta dentro do contexto recuperado pelo sistema de retrieval.

O modelo utilizado foi:

- deepset/roberta-base-squad2
- versão com fine-tuning adicional sobre SQuAD

O funcionamento do sistema segue os seguintes passos:

1. O utilizador coloca uma pergunta;
2. O retriever devolve os chunks mais relevantes;
3. O modelo analisa o contexto;
4. São calculados os logits de início e fim da resposta;
5. É selecionado o span textual com maior probabilidade.

Foram também adicionadas várias heurísticas para melhorar a qualidade das respostas:

- limitação do tamanho máximo da resposta;
- remoção de spans inválidos;
- penalização de palavras irrelevantes;
- regras específicas para perguntas sobre vencedores;
- função de correção automática de respostas.

```
Pergunta (ou 'sair'): who win 2017 eurovision

--- CONTEXTO USADO ---
Portugal won with 758 points, winning both the jury vote and the televote.
-----

===== RESPOSTA =====
Resposta: Portugal
Score: 4.8869
=====
```


QA ABSTRATIVO

Foi desenvolvido um segundo módulo de Question Answering abstrativo, baseado em geração de texto, com o objetivo de produzir respostas mais naturais e flexíveis.

O modelo generativo utilizado foi:

- google/flan-t5-base

O sistema segue uma abordagem híbrida:

1. A pergunta é normalizada;
2. É realizado retrieval semântico com S-BERT;
3. São selecionados os chunks mais relevantes;
4. O contexto é refinado com seleção de evidência;
5. O modelo FLAN-T5 gera a resposta final.

Foram ainda aplicados vários filtros e heurísticas:

- filtragem por ano;
- separação entre Eurovision e Junior Eurovision;
- penalização de contexto irrelevante;
- prioridade a frases com padrões de vitória.

O sistema utiliza:

- beam search;
- geração determinística;
- limite máximo de tokens.

Pergunta: who win 2017 eurovision?

===== RESPOSTA =====

Portugal won with 758 points

Pergunta: winner 2009 eurovision junior?

===== RESPOSTA =====

The Netherlands won with 121 points

COMPARAÇÃO

Este trabalho comparou diferentes abordagens ao longo de todo o pipeline de Question Answering, desde o retrieval até à geração de respostas.

Retrieval

- TF-IDF (lexical): eficiente e simples, mas limitado a correspondência de palavras.
- S-BERT (semântico): melhor compreensão do significado e maior robustez a sinónimos.

Question Answering

- Extrativo:
 - Alta precisão em perguntas factuais
 - Respostas diretamente retiradas do texto
 - Menor flexibilidade
- Abstrativo:
 - Respostas mais naturais e fluídas
 - Capacidade de reformulação
 - Maior risco de erros (alucinação)

CONCLUSÃO

- Foi desenvolvido um sistema completo de Question Answering sobre o Eurovision Song Contest baseado em arquitetura RAG
- O sistema é capaz de responder corretamente a muitas perguntas factuais, especialmente quando o contexto recuperado é relevante
- No entanto, o desempenho não é perfeito e pode variar dependendo da qualidade do retrieval e da formulação da pergunta
- O modelo S-BERT e as heurísticas aplicadas melhoram significativamente a qualidade das respostas
- O QA extrativo apresenta maior precisão, enquanto o abstrativo oferece maior flexibilidade linguística

O sistema demonstra bons resultados, mas ainda apresenta limitações típicas de sistemas baseados em retrieval e modelos de linguagem

QUESTION ANSWERING SOBRE O EUROVISION SONG CONTEST

SPLN

