

YAKE!

Keyword Extraction from Single
● Documents Using Multiple Local Features

O Problema

Algoritmos existentes

Antes do YAKE!, já existiam vários métodos de keyword extraction:

- TF-IDF — usa frequência das palavras num corpus
- RAKE — baseado em co-ocorrência de palavras
- TextRank — utiliza grafos e PageRank
- KEA — abordagem supervisionada com machine learning

Problemas destes métodos:

- muitos precisam de grandes coleções de documentos
- alguns necessitam de treino
- podem depender da língua ou domínio
- alguns são mais pesados computacionalmente

YAKE!

Porque foi criado?

Os métodos anteriores tinham vários problemas:

- precisavam de datasets anotados
- necessitavam de treino
- dependiam de corpus externos
- usavam ferramentas linguísticas complexas
- eram difíceis de adaptar a novas línguas e domínios

Objetivo


Criar um método:

- unsupervised
- simples e rápido
- baseado apenas num único documento
- independente da língua e domínio

Ideia Chave

Extrair keywords usando apenas estatísticas locais do texto.

YAKE! - Pipeline



YAKE!

1

Separação do texto

1. Frases

O documento é dividido em frases usando a pontuação final (p. final, p. interrogação, p. exclamação).

2. Chunks

Cada frase é dividida em pequenos blocos separados por pontuação intermédia (virgulas, parênteses, dois pontos).

3. Tokens

Os chunks são divididos em palavras individuais.

Identificação do tipo de palavras

1. Acrónimos

Acrónimos costumam representar conceitos importantes ou técnicos → O algoritmo aumenta a relevância destes termos.

2. Palavras iniciadas por maiúscula

Podem representar nomes próprios, entidades importantes ou conceitos relevantes → O algoritmo dá maior peso a estes candidatos.

3. Stopwords

O YAKE! não permite que expressões comecem ou terminem com stopwords, mas aceita-as no meio da frase → Evita palavras-chave incompletas e preserva conceitos legítimos

YAKE!

2

Features utilizadas

- **TCase** = $\frac{\max(TF(U(t)), TF(A(t)))}{\ln(TF(t))}$

Importância de maiúsculas e acrónimos.

- **TPosition** = $\ln(\ln(3 + \text{Median}(Sen_t)))$

Posição do termo no documento.

- **TFNorm** = $\frac{TF(t)}{\text{MeanTF} + 1 \times \sigma}$

Frequência do termo.

- **TRel** = $1 \times (DL + DR \dots) \times \frac{TF(t)}{\text{MaxTF}}$

Relação do termo com o contexto.

- **TSentence** = $\frac{SF(t)}{\#Sentences}$

Distribuição do termo pelas frases.

3

Score do termo

$$S(t) = \frac{T_{Rel} \times T_{Position}}{T_{Case} + \frac{TF_{Norm}}{T_{Rel}} + \frac{T_{Sentence}}{T_{Rel}}}$$

score menor = termo mais relevante

YAKE!

4

Geração de n-grams

Depois de calculado o score dos termos, vão ser criadas keywords candidatas através de unigramas, bigramas e trigramas

Como são criados?

Só podem ser formados dentro do mesmo chunk e só utilizam termos relevantes para evitar keywords sem sentido entre partes diferentes da frase

5

Deduplicação e Ranking

- Cada n-grama recebe um score baseado no score do termo e na frequência da keyword no documento.
- São removidas keywords muito semelhantes entre si utilizando as técnicas Similaridade de Levenshtein, a Similaridade de Jaro-Winkler e o Sequence matcher
- As keywords finais são ordenadas pelo score, da mais para a menos relevante, gerando assim a lista das keywords finais

Resultados

Avaliação experimental abrangente (20 datasets, 5 idiomas e 11 algoritmos concorrentes) → O YAKE! superou o estado da arte na maioria dos cenários.

- **Superioridade em Precisão e Recall:** Bateu com folga métodos tradicionais não supervisionados (como TextRank e RAKE) tanto em textos curtos como longos.
- **Independência de Tamanho e Idioma:** Manteve resultados altamente consistentes e estáveis em múltiplos idiomas (PT, EN, ES, FR, PL), sem sofrer perda de performance com a variação do tamanho do texto.
- **Eficiência Computacional:** Demonstrou uma complexidade de processamento linear → É significativamente mais rápido e leve do que métodos baseados em grafos.

Dataset	YAKE! is better		YAKE! is worst	
	▲	△	▼	▽
110-PT-BN-KP	100%	0%	0%	0%
500N-KPCrowd-v1.1	82%	0%	10%	0%
Inspec	73%	0%	27%	0%
Krapivin2009	82%	0%	9%	0%
Nguyen2007	91%	0%	9%	0%
PubMed	82%	0%	9%	9%
Schutz2008	73%	0%	27%	8%
WWW	100%	0%	0%	0%
KDD	100%	0%	0%	0%
SemEval2010	64%	9%	9%	0%
SemEval2017	55%	0%	27%	0%
cacic	100%	0%	0%	0%
citeulike180	82%	0%	9%	0%
fao30	82%	9%	0%	0%
fao780	100%	0%	0%	0%
pak2018	100%	0%	0%	0%
theses100	55%	0%	9%	0%
wicc	100%	0%	0%	0%
wiki20	73%	9%	0%	0%
WikiNews	100%	0%	0%	0%

Method	YAKE! is better		YAKE! is worse	
	▲	△	▼	▽
TF.IDF	90%	5%	0%	0%
KP-Miner	55%	0%	25%	5%
Rake	100%	0%	0%	0%
TextRank	100%	0%	0%	0%
Single Rank	90%	0%	10%	0%
TopicRank	70%	10%	5%	10%
TopicalPageRank	90%	0%	10%	0%
PositionRank	90%	0%	10%	0%
MultipartiteRank	75%	0%	5%	0%
ExpandRank	100%	0%	0%	0%
KEA	70%	0%	10%	0%

Conclusões e Trabalho Futuro

O YAKE! equilibra perfeitamente a simplicidade estatística com a eficácia de resultados → Os autores validaram o método e delinearam a sua evolução no próprio artigo.

- **Fim do Cold-Start Problem:** Prova que é possível extrair palavras-chave de altíssima qualidade olhando apenas para as características locais de um único documento.
- **Solução Prática e Universal:** Dispensa dicionários ou analisadores gramaticais (PoS taggers), facilitando a integração em sistemas de tempo real e o suporte a múltiplos idiomas.
- **Resolução de Palavras-chave Ausentes (Trabalho Futuro):** Proposta dos autores para desenvolver formas de sugerir conceitos centrais que definem o tema do texto, mesmo que as palavras exatas não estejam escritas no documento.
- **Integração de Semântica Profunda (Trabalho Futuro):** Intenção dos autores de explorar o uso de Word Embeddings para capturar sinónimos e relações contextuais mais complexas entre os termos.

YAKE!

Keyword Extraction from Single
● Documents Using Multiple Local Features