

Scripting no Processamento de Linguagem Natural

Trabalho Prático 2

Ano Letivo 2025/26

Objetivos e Organização

Esta parte do trabalho prático tem como principais **objetivos**:

- colocar em prática os conhecimentos adquiridos em word embeddings;
- fine tuning de modelos de linguagem pré-treinados;
- transformers e information retrieval;

Enunciado

Este trabalho prático tem duas partes.

Parte 1 - Implementação prática de uma pipeline de information retrieval

Escolha um tema do seu interesse e implemente as seguintes tarefas:

- a) Construa um corpus de texto a partir de fontes de dados à sua escolha acerca do tema de interesse. O corpus deve conter pelo menos 100 documentos. Deve efetuar o processamento de texto que achar adequado em função das tarefas seguintes.
- b) Desenvolva um módulo retriever para o corpus escolhido. O retriever deve ser capaz de receber uma query e retornar os documentos mais relevantes para a query. A pesquisa pode ser léxica ou semântica ou uma combinação das duas.
- c) Desenvolva um módulo de extração de informação para o corpus escolhido. O módulo deve ser capaz de extrair informações relevantes dos documentos retornados pelo retriever. A solução deve seguir o paradigma de question answering (QA), ou seja, deve ser capaz de responder a perguntas inseridas pelo utilizador. Devem implementar uma estratégia extrativa (fazer o fine-tuning de um modelo QA usando o SQuAD dataset mencionado num dos artigos em baixo) e também uma abstrativa (usando prompting a um modelo generativo).

Entrega e Apresentação Devem submeter os artefactos produzidos no elearning na véspera do dia 26, incluindo o código Python e um relatório em formato PDF. O relatório deve conter uma descrição detalhada do trabalho realizado, os resultados obtidos e as conclusões tiradas. Na aula de dia 26 todos os alunos deverão apresentar o seu trabalho. A apresentação deve demorar no máximo 10 minutos, e dar uma ideia geral dos resultados obtidos e as conclusões tiradas.

Parte 2 - Atividade Grupo de Leitura

Ler e apresentar um artigo científico da seguinte lista relacionado com os tópicos lecionados:

- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 2017
- Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks, 2019
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks, 2020
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space, 2013
- Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. Squad: 100,000+ questions for machine comprehension of text, 2016
- Ricardo Campos, Vítor Mangaravite, Arian Pasquali, Alípio Jorge, Célia Nunes, and Adam Jatowt. Yake! keyword extraction from single documents using multiple local features. *Information Sciences*, 509:257–289, 2020
- Christopher D. Manning. Human language understanding & reasoning. *Daedalus*, 151(2):127–138, 2022

Cada artigo pode ser escolhido no máximo por dois alunos. A apresentação deve demorar no máximo 10 minutos, e dar uma ideia geral dos resultados obtidos e as conclusões tiradas. A apresentação deve ser submetida no elearning na véspera do dia 19 de Maio. Na aula de dia 19 todos os alunos deverão trazer a apresentação dos artigos para uma atividade de grupo de leitura a definir na aula.

Trabalho Alternativo: Mini-projecto de investigação

Em alternativa às Parte 1 e 2, os podem optar por realizar um mini-projecto de investigação num dos tópicos lecionados à escolha. O mini-projecto deve incluir a leitura e apresentação de um artigo científico relevante para o tópico escolhido, e um demo em Python relacionado com o tópico na aula de dia 26. Esta alternativa deve ser validada pelo professor até dia 12 de Maio

Referências

- [1] Ricardo Campos, Vítor Mangaravite, Arian Pasquali, Alípio Jorge, Célia Nunes, and Adam Jatowt. Yake! keyword extraction from single documents using multiple local features. *Information Sciences*, 509:257–289, 2020.
- [2] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks, 2020.
- [3] Christopher D. Manning. Human language understanding & reasoning. *Daedalus*, 151(2):127–138, 2022.
- [4] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space, 2013.
- [5] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. Squad: 100,000+ questions for machine comprehension of text, 2016.
- [6] Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks, 2019.
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 2017.